Hadoop Ecosystem

Overview

Hadoop

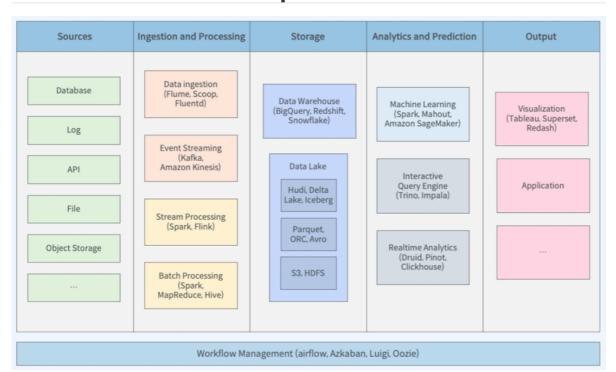
- 분산 파일 시스템
 - HDFS(Dadoop Distributed File System)
- 리소스 관리자
 - YARN(Yet Another Resource Negotitation)
- 분산 데이터 처리
 - MapReduce

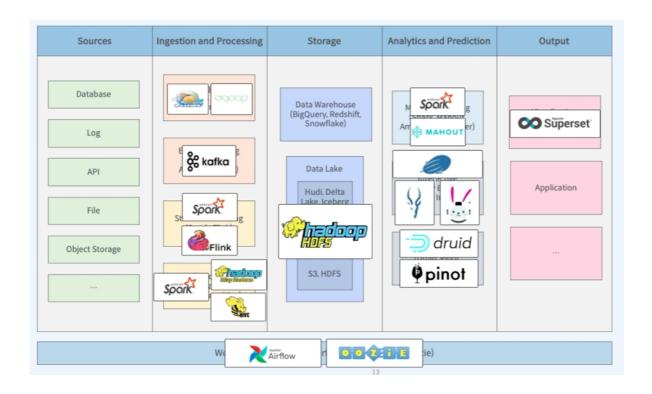


- 데이터 수집
 - o Apache Flume
 - Kafka
- 데이터 처리
 - MapReduce
 - o Spark 배치, 스트리밍, 그래프 처리, ML 제공
 - 현재 가장 많이 사용되고 있는 데이터 처리 시스템
 - 메모리에서 처리함으로써 속도가 빠름
 - SparkQL을 이용한 배치 처리 또한 가능
 - HIVE SQL을 통해 배치 처리를 할 수 있도록함, 구조화된 데이터를 HiveQL을 통해 처리
 - o Impala 대화형 쿼리 엔진
 - o Flink
 - o Kafka
- 데이터 저장
 - o HDFS 분산 Object Storage
 - 데이터를 데이터 소스로 하여 배치 처리 가능
 - NoSQL의 저장소로 사용 가능
 - Storage Layer를 두어 고도화된

- 데이터 웨어하우스로도 사용 가능하다.
- o HBASE NoSQL
- 데이터 분석
 - ㅇ 대화형 쿼리 엔진
 - Trino
 - Impala
 - ㅇ 실시간 분석
 - Druid
 - Pinot
 - ㅇ 머신러닝
 - Spark MLlib 제공
 - Mahout
- Zoo keeper 서버간의 상호 조정을 위한 서비스 제공
- Workflow 관리 도구
 - o Apache Airflow
 - o Oozie
- 보안
 - o Apache Ranger 권한 부여 및 엑세스 제어
- 메타데이터 관리
 - o Apache Atlas 테이블 컬럼을 해시태그를 이용해서 검색 가능, 특정 컬럼에 대한 마스킹 or 접 근제한 제공
- Notebook
 - o Apache Zetplin 분석 결과를 테이블 및 그래프로 보여줌
- Visualization
 - Apache Superset

빅데이터 플랫폼과 Hadoop



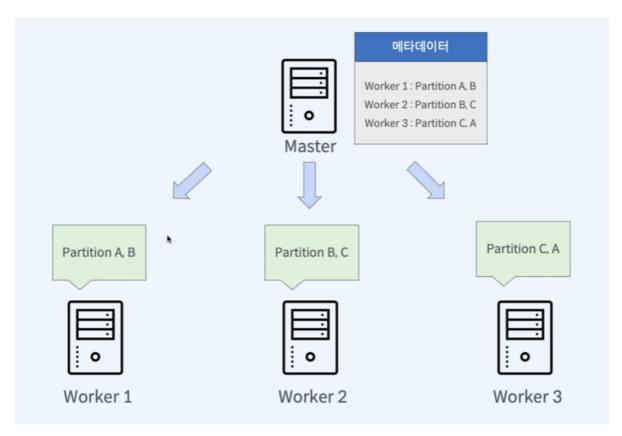


Hadoop Cluster 구축 고려사항

클러스터란?

- 정의
 - ㅇ 여러 대의 컴퓨터들이 연결되어 하나의 시스템처럼 동작하는 컴퓨터들의 집합
 - o Master와 Worker로 구성
 - o Master Worker 노드들을 조율, Worker에서 실행되는 서비스나 데이터에 대한 메타데이터 관리
 - 2~3대로 구성
 - o Worker 실제로 작업을 수행하는 노드, 데이터 처리 or 조회
 - 만은
 - ㅇ Gateway Master와 Worker에 접근할 수 있도록 하는 노드

Master-Worker 구조



- 주 업무 하나와 부 업무를 두어 하나의 노드에 문제가 발생하더라도 다른 서버가 해결할 수 있도록 함
- 에러 발생을 대비해 Partition들의 복제본들을 다른 Worker에 저장해둔다.

클러스터의 규모 결정

클러스터의 규모보다 데이터의 수와 증가 속도에 대한 고려가 필요!

- 스토리지 용량으로 결정하기
 - ㅇ 저장될 데이터 크기 예측
 - 복제 전략 결정 일반적으로는 Replication Factor = 3으로 설정되어있음
 - ㅇ 저장 기간 고려
 - ㅇ 필요한 노드 수 결정
 - ㅇ 추가 고려사항
 - 데이터 포맷
 - 데이터 압축 여부
 - 데이터 증가율의 변화

- 예시
 - 저장될 데이터 크기 예측
 - 하루에 저장되는 데이터의 크기는 1TB
 - 복제 전략 결정
 - 복제 계수는 3
 - 저장 기간 고려
 - 3년
 - 필요한 노드 수 결정
 - 서버 한대의 저장 용량: 5TB * 12
 - 약 70대

• 데이터 수집 속도로 결정하기

- ㅇ 데이터 수집 속도 예측
- ㅇ 데이터 처리 속도 예측
 - 데이터 수집 속도로 결정하기
 - 1TB 데이터 분석
 - 5분 이내에 결과를 저장
 - 쓰기 속도는 디스크당 초당 50MB
 - 디스크 70개가 병렬로 써야함
 - 서버당 디스크가 24개씩 있는 경우
 - 약 3대의 서버가 필요

• 클러스터 하드 웨어 결정

- ㅇ 워크로드에 따른 하드웨어 선정
 - CPU 분석을 위해서는 연산 속도가 빨라야 하므로 중요
 - Memory 분석을 위해서는 연산 속도가 빨라야 하므로 중요
 - I/O

11